

矩阵论复习笔记

修改时间: 2018.12.26 E-mail: zhushuai0403@163.com

1. 线性空间与线性变换

(1) 线性空间的定义:

以 $\alpha, \beta, \gamma, \dots$ 为元素的非空集合 V , 数域 F , 定义两种运算: **加法** $\forall \alpha, \beta \in V, \alpha + \beta \in V$; **数乘** $\forall k \in F, \alpha \in V, k\alpha \in V$ 。满足8条: **加法交换律、加法结合律、数乘结合律、两个分配律, 0元存在, 1元存在, 负元存在**。称 V 为数域 F 上的线性空间。

(2) 证明一组向量是线性空间的基, 两步走:

- 证明这组向量线性无关;
- 证明线性空间任意向量可由这组向量表示。

(3) 如果 $\{E_{ij}, i = 1, 2, \dots, m; j = 1, 2, \dots, n\}$ 是矩阵空间 $R^{m \times n}$ 的一组基, 则 $\dim R^{m \times n} = m \times n$ 。

注: 这里有前提条件, 实际上 $\dim R^{m \times n}$ 并不是总等于 $m \times n$, 如2015年填空题第2题。

(4) $\alpha_1, \alpha_2, \dots, \alpha_n$ 是线性空间 $V_n(F)$ 的一组基, 对于 $\forall \beta \in V$,

$$\beta = (\alpha_1 \ \alpha_2 \ \dots \ \alpha_n) \begin{bmatrix} x_1 \\ x_2 \\ \dots \\ x_n \end{bmatrix} = (\alpha_1 \ \alpha_2 \ \dots \ \alpha_n) X$$

其中 X 称为向量 β 在基 $(\alpha_1 \ \alpha_2 \ \dots \ \alpha_n)$ 下对应的坐标。

$V_n(F)$ 中向量组 $\{\beta_1 \ \beta_2 \ \dots \ \beta_m\}$ 线性相关的充要条件是坐标向量组 $\{X_1, X_2, \dots, X_m\}$ 是线性相关组。

(5) 设 $(\alpha_1 \ \alpha_2 \ \dots \ \alpha_n)$ 和 $(\beta_1 \ \beta_2 \ \dots \ \beta_n)$ 是 n 维线性空间 $V_n(F)$ 中的两组基, 则有 $C \in F^{m \times n}$

$$(\beta_1 \ \beta_2 \ \dots \ \beta_n) = (\alpha_1 \ \alpha_2 \ \dots \ \alpha_n) C$$

其中 C 称为从基 $(\alpha_1 \ \alpha_2 \ \dots \ \alpha_n)$ 到 $(\beta_1 \ \beta_2 \ \dots \ \beta_n)$ 的过渡矩阵。

重要推论: 如果向量 $\alpha \in V_n(F)$, α 在两组基下对应坐标分别是 X 和 Y , 则有:

$$\alpha = (\alpha_1 \ \alpha_2 \ \dots \ \alpha_n) X$$

$$\alpha = (\beta_1 \ \beta_2 \ \dots \ \beta_n) Y$$

显然有: $X = CY$ 。

(6) 设 W 是线性空间 $V_n(F)$ 的非空子集, 则 W 是 $V_n(F)$ 的子空间的充要条件是:

- 若 $\alpha, \beta \in W$, 则 $\alpha + \beta \in W$
- 若 $\alpha \in W, k \in F$, 则 $k\alpha \in W$

也就是说只需要验证对加法和数乘封闭即可。

(7) 设 W_1, W_2 是线性空间 V 的子空间, 则:

- W_1 与 W_2 的交空间为: $W_1 \cap W_2 = \{\alpha | \alpha \in W_1 \text{ and } \alpha \in W_2\}$
- W_1 与 W_2 的和空间为: $W_1 + W_2 = \{\alpha | \alpha = \alpha_1 + \alpha_2, \alpha_1 \in W_1, \alpha_2 \in W_2\}$

两个重要的维数公式

- $\dim(W_1 \cap W_2) \leq \dim W_i \leq \dim(W_1 + W_2) \leq \dim V$
- $\dim W_1 + \dim W_2 = \dim(W_1 + W_2) + \dim(W_1 \cap W_2)$

直和子空间: 如果 $W = W_1 + W_2$, 并且 $W_1 \cap W_2 = \{0\}$, 那么称 W 是 W_1 与 W_2 的直和子空间, 表示为 $W = W_1 \oplus W_2$ 。

直和补子空间: 对 n 维空间 V 的任何子空间 W , 设 $\alpha_1, \dots, \alpha_r$ 为 W 的基, $r < n$, 把它们扩充为 V 的基 $\{\alpha_1, \dots, \alpha_r; \beta_{r+1}, \dots, \beta_n\}$, $U = L\{\beta_{r+1}, \dots, \beta_n\}$, 有 $V = W \oplus U$ 成立, 则称 U 是 W 的直和补子空间。

(8) 若 $(\alpha_1 \ \alpha_2 \ \dots \ \alpha_n)$ 是线性空间 $V_n(F)$ 的一组基, 则

$$V_n(F) = L\{\alpha_1, \alpha_2, \dots, \alpha_n\}$$

对一个矩阵 $A \in F^{m \times n}$, 可以得到两个与 A 相关的子空间:

$$N(A) = \{X | AX = 0\} \subseteq F^n$$

$$R(A) = L\{A_1, A_2, \dots, A_n\} \subseteq F^m$$

其中 $N(A)$ 称为矩阵 A 的零空间, $R(A)$ 称为矩阵 A 的列空间。

(9) 内积:

- 欧氏空间的内积: $(\alpha, \beta) = \alpha^T \beta; \quad (A, B) = \text{tr}(AB^T)$
- 酉空间的内积: $(\alpha, \beta) = \beta^H \alpha; \quad (A, B) = \text{tr}(B^H A)$

柯西不等式: $|(\alpha, \beta)|^2 \leq (\alpha, \alpha)(\beta, \beta)$

正交补子空间: 设 U 为内积空间 $V_n(F)$ 的一个子空间, 定义 $V_n(F)$ 上的一个子集

$U^\perp = \{\alpha | \alpha \in V_n(F), \forall \beta \in U, (\alpha, \beta) = 0\}$ 称为 U 的正交补子空间, 有 $V_n(F) = U \oplus U^\perp$ 。

(10) 设 T 是线性空间 $V_n(F)$ 上的线性变换, 则满足 $T(k_1 \alpha_1 + k_2 \alpha_2) = k_1 T(\alpha_1) + k_2 T(\alpha_2)$, 则有:

像空间: $R(T) = \{\beta | \exists \alpha \in V_n(F), s.t. \beta = T(\alpha)\}$ 是 $V_n(F)$ 上的子空间, 称为 T 的像空间; $\dim R(T)$ 称为 T 的秩。

零空间: $N(T) = \{\alpha | T(\alpha) = 0\}$ 是 $V_n(F)$ 上的子空间, 称为 T 的零空间; $\dim N(T)$ 称为 T 的零度。

(11) 设 T 为 $V_n(F)$ 上的线性变换, $\{\alpha_1, \alpha_2, \dots, \alpha_n\}$ 是 $V_n(F)$ 的基, 若存在 n 阶方阵 A , 有:

$$T(\alpha_1 \ \alpha_2 \ \dots \ \alpha_n) = (\alpha_1 \ \alpha_2 \ \dots \ \alpha_n)A$$

称 A 为 T 在基 $\{\alpha_1, \alpha_2, \dots, \alpha_n\}$ 下的矩阵。

- 设 α 与 $T(\alpha)$ 在基 $\{\alpha_1, \alpha_2, \dots, \alpha_n\}$ 下的坐标分别是 X 与 Y , 则有: $Y = AX$ 。
- 设 $\{\alpha_1, \alpha_2, \dots, \alpha_n\}$ 和 $\{\beta_1, \beta_2, \dots, \beta_n\}$ 是 $V_n(F)$ 的两组基, 且有 $(\beta_1 \ \beta_2 \ \dots \ \beta_n) = (\alpha_1 \ \alpha_2 \ \dots \ \alpha_n)C$; T 在两组基下的变换矩阵分别是 A 与 B , 则 $B = C^{-1}AC$ 。

(12) 设 T 是线性空间 $V_n(F)$ 上的线性变换, W 是 $V_n(F)$ 的子空间, 如果 $\forall \alpha \in W, T(\alpha) \in W$, 即值域 $T(W) \subseteq W$, 则称 W 是 T 的**不变子空间**。

重要例题

设 T 是欧式空间 R^3 上的线性变换, 对 R^3 中单位矢量 u , $\forall x \in R^3, T(x) = x - (1-k)(x, u)u$, 问: T 的不变子空间的直和分解以及相应的矩阵分解。

答: 对向量 u 有 $T(u) = u - (1-k)(u, u)u = u - (1-k)u = ku$ 所以以 u 为基向量的空间是不变子空间, 表示为 $L\{u\}$;

同理, 对于 u 的正交补子空间 u^\perp , 对于任意向量 $X \in u^\perp$, 有

$T(X) = X - (1-k)(X, u)u = X - 0 = X$ 于是另一个不变子空间为 u^\perp ; 即 $R^3 = L\{u\} \oplus u^\perp$ 。

显然有 $L\{u\}$ 是一维空间, 特征值 k 对应的特征向量是 $u_1 = u$; 那么 u^\perp 就是二维空间, 特征值1对应两个

线性无关的特征向量, 可以找到两个单位正交特征向量 u_2, u_3 , 所以相应的矩阵分解为 $\begin{bmatrix} k & & \\ & 1 & \\ & & 1 \end{bmatrix}$, 对

应的特征向量组 $\{u_1, u_2, u_3\}$ 为标准正交基。

(13) **正交变换 (酉变换)**: 线性变换 T 不改变向量内积, 即 $(T(\alpha), T(\beta)) = (\alpha, \beta)$ 。

- 正交变换 T 关于任一标准正交基的矩阵 C 满足 $C^T C = C C^T = I$; 酉变换关于任一标准正交基的矩阵 U 满足 $U^H U = U U^H = I$ 。
- 正交矩阵的行列式为 ± 1 ; 酉矩阵的行列式的模长为1。

(14) **常见的正交变换**

- R^2 上绕原点逆时针旋转 θ 角的线性变换 T_θ 称为**正交变换**, 在标准正交基下对应的变换矩阵 $\begin{bmatrix} \cos \theta & -\sin \theta \\ \sin \theta & \cos \theta \end{bmatrix}$ 是**正交矩阵**。

- 空间 R^3 上绕过原点的直线 l 旋转 θ 角的变化 T_{L_θ} 为**正交变换**, 在标准正交基下对应的变换矩阵

$$\begin{bmatrix} 1 & & \\ & \cos \theta & -\sin \theta \\ & \sin \theta & \cos \theta \end{bmatrix} \text{ 是正交矩阵。}$$

2. Jordan标准形

(1) 若有 $T(\xi) = \lambda\xi$, 称 λ 为 T 的特征值, ξ 为 T 的特征向量。如果 A 是线性变换 T 对应的矩阵, 那么, λ 和 ξ 也是 A 的特征值和特征向量。

(2) 设 $\lambda_1, \lambda_2, \dots, \lambda_s$ 是 $V_n(F)$ 上线性变换 T 的 s 个互异特征值, V_{λ_i} 是 λ_i 的特征子空间, 其中 $i = 1, 2, \dots, s$, 则:

- V_{λ_i} 是 T 的不变子空间;
- $\lambda_i \neq \lambda_j$ 时, $V_{\lambda_i} \cap V_{\lambda_j} = 0$;
- 若 λ_i 是 k_i 重 (代数重数) 的, $\dim V_{\lambda_i}$ 是几何重数, 则有 $\dim V_{\lambda_i} \leq k_i$ 。

(3) 线性变换 T 有对角矩阵表示的充分必要条件是 T 有 n 个线性无关的特征向量。

幂等矩阵: $A^2 = A$, A 相似于对角矩阵 $\begin{bmatrix} I_r & \\ & 0 \end{bmatrix}$, 其中 r 为矩阵 A 的秩。

乘方矩阵: $A^2 = I$, A 相似于对角阵 $\begin{bmatrix} I_s & \\ & I_t \end{bmatrix}$, 其中 $s + t = n$ 。

(4) 关于秩的不等式:

$$\text{rank}(A \pm B) \leq \text{rank}(A) + \text{rank}(B)$$

$$\text{rank}(A) + \text{rank}(B) - n \leq \text{rank}(A_{m \times n} B_{n \times m}) \leq \min(r(A), r(B))$$

$$\text{if } A_{m \times n} B_{n \times m} = 0, \quad \text{rank}(A) + \text{rank}(B) \leq n$$

(5) 形如 $J(\lambda) = \begin{bmatrix} \lambda & 1 & & \\ & \lambda & 1 & \\ & & \ddots & 1 \\ & & & \lambda \end{bmatrix}$, 称为 **Jordan块**。Jordan块呈上三角, 主对角线是它的全部特征值, 特点是主对角线上元素相等, 紧邻上方元素 $a_{i,i+1} = 1$, 其余元素为0。

(6) 每个 n 阶方阵 A 都相似于一个 Jordan 矩阵, 即存在可逆矩阵 P , 有:

$$P^{-1}AP = J_A = \begin{bmatrix} J_1(\lambda_1) & & & \\ & J_2(\lambda_2) & & \\ & & \ddots & \\ & & & J_s(\lambda_s) \end{bmatrix}$$

其中 J_A 称为 **Jordan标准形**。

(7) **Jordan标准形**的求法:

- 求矩阵 A 的特征多项式 $|\lambda I - A| = (\lambda - \lambda_1)^{k_1} (\lambda - \lambda_2)^{k_2} \dots (\lambda - \lambda_s)^{k_s}$, 其中 k_i 是特征值 λ_i 的代数重数, 决定了对角线上特征值 λ_i 的个数;
- 对 λ_i , 由 $(A - \lambda_i I)X = 0$, 求 A 的线性无关的特征向量 $\alpha_1, \alpha_2, \dots, \alpha_{t_i}$, 其中 t_i 是特征值 λ_i 的几何重数, 决定了 Jordan 块的个数;

- 如果 $k_i = t_i$, 即**代数重数等于几何重数**, 说明 λ_i 对应的Jordan块是对角阵;
 - 如果 $t_i < k_i$, 就选择合适的特征向量 α_j , 利用 $|A - \lambda_i I| = \alpha_j$ **求Jordan链**, 确定每一个小Jordan块的阶数。
- 将所有特征值 λ_i 对应的Jordan块组合起来, 形成Jordan矩阵 J_A 。

(8) **矩阵多项式**可以表示为 $g(A) = a_m A^m + a_{m-1} A^{m-1} + \dots + a_1 A + a_0 I$, 由于有 $A = P J_A P^{-1}$, 所以有:

$$g(A) = P \begin{bmatrix} g(J_1(\lambda_1)) & & & \\ & g(J_2(\lambda_2)) & & \\ & & \dots & \\ & & & g(J_s(\lambda_s)) \end{bmatrix} P^{-1}$$

而对于 $g(J(\lambda))$ 则有:

$$g(J(\lambda)) = \begin{bmatrix} g(\lambda) & g'(\lambda) & \dots & \frac{g^{(r-1)}(\lambda)}{(r-1)!} \\ & g(\lambda) & \dots & \cdot \\ & & \dots & \cdot \\ & & & g(\lambda) \end{bmatrix}$$

对于**常用的幂指数形式**有:

$$J^k(\lambda) = \begin{bmatrix} \lambda^k & \frac{(\lambda^k)'}{1!} & \frac{(\lambda^k)''}{2!} & \dots \\ & \lambda^k & \dots & \cdot \\ & & \dots & \cdot \\ & & & \lambda^k \end{bmatrix}$$

(9) 使 $g(A) = 0$ 的多项式 $g(\lambda)$ 称为 A 的**化零多项式**, **特征多项式必是矩阵 A 的化零多项式**。

注: 化零多项式的根一定包含了所有的特征值, 但不能说化零多项式的根一定是特征值。

(10) 对于**最小多项式** $m_T(\lambda)$

- $m_T(\lambda)$ 最高项系数为 1;
- $m_T(\lambda)$ 是 T 的一个化零多项式;
- $m_T(\lambda)$ 是化零多项式中次数最低的那一个。

最小多项式 $m_T(\lambda)$ 的根一定包含了所有的特征值 λ_i , 子式 $(\lambda - \lambda_i)^{r_i}$ 的幂 r_i 等于Jordan标准形中关于特征值 λ_i 的Jordan块中的最高阶数。

比如矩阵 A 有一个代数重数为 3 的特征值 2, 该特征值对应两个Jordan块, 分别是 $\begin{bmatrix} 2 & 1 \\ & 2 \end{bmatrix}$ 以及 $[2]$, 说明其中其最高阶数为 2, 那么在最小多项式中对应的子式为 $(\lambda - 2)^2$ 。

3. 矩阵的分解

(1) **等价标准形**

对于 $A \in C^{m \times n}$, 存在可逆矩阵 $P \in C^{m \times m}, Q \in C^{n \times n}$, 使得

$$A = P \begin{bmatrix} I_r & 0 \\ 0 & 0 \end{bmatrix} Q$$

其中 r 是矩阵 A 的秩。

(2) 相似标准形

存在可逆矩阵 $P \in C^{n \times n}$, 有

$$A = P \begin{bmatrix} \lambda_1 & & & \\ & \lambda_2 & & \\ & & \dots & \\ & & & \lambda_n \end{bmatrix} P^{-1}$$

(3) LU分解

定义: L 是下三角矩阵, U 是上三角矩阵, $A = LU$ 。

求法:

- 对于 $(A | I_n)$, 只用第 i 行乘数 k 加到第 j 行 ($i < j$) 型初等变换将 A 化为上三角形 U , 可以得到 $(U | P)$;
- 可知 $PA = U$, 于是有 $L = P^{-1}$, 则 $A = LU$ 。

(4) LDV分解

定义: L, V 分别是对角线元素为1的下三角矩阵和上三角矩阵, D 为对角矩阵, $A = LDV$ 。

求法:

方法一:

- 由LU分解得到 $A = LU$;
- 通过每行除以对应的对角线上元素的值, 将 U 的对角线元素化为1, 得到 $U = DV$;
- 有 $A = LDV$ 。

方法二:

- 取矩阵 A 对角线第一个元素, 得到矩阵 $A_1 = [a_{11}]$, 则有 $A_1 = L_1 D_1 V_1 = [1][a_{11}][1]$;
- 取包含对角线前两个元素的二阶矩阵 $A_2 = \begin{bmatrix} A_1 & \alpha \\ \beta & a_{22} \end{bmatrix}$, 则有矩阵 $A_2 = L_2 D_2 V_2$, 其中 $L_2 = \begin{bmatrix} L_1 & 0 \\ x & 1 \end{bmatrix}$,
 $D_2 = \begin{bmatrix} D_1 & 0 \\ 0 & d_2 \end{bmatrix}$, $V_2 = \begin{bmatrix} V_1 & y \\ 0 & 1 \end{bmatrix}$, 求得未知量 x, d_2, y ;
- 以此类推, 最终得到 $A = L_n D_n V_n$ 。

(5) 满秩分解

定义: 对于 $\text{rank}(A) = r$ 的矩阵 A , 若存在秩为 r 的矩阵 $B \in F^{m \times r}, C \in F^{r \times n}$, 有 $A = BC$, 称为矩阵 A 的满秩分解。

求法: 方法较多, 一般只用最简单的第3种。

- 用行初等变换把 A 化为 Hermite 标准形;
- 依 Hermite 标准形中向量 e_i 所在的列的位置第 j_i 列, 相应地取出 A 的第 j_i 列 a_{j_i} , 得到 A 的列向量极大无关组 $\{a_{j_1}, a_{j_2}, \dots, a_{j_r}\}$, $B = (a_{j_1}, a_{j_2}, \dots, a_{j_r})$;
- A 的 Hermite 矩阵中的非零行构成矩阵 C , 得到满秩分解 $A = BC$ 。

举个例子:

求矩阵 $A = \begin{bmatrix} 1 & 1 & 2 \\ 0 & 2 & 2 \\ 1 & 0 & 1 \end{bmatrix}$ 的满秩分解。

答: 用行初等变换化 A 为 Hermite 标准形:

$$A = \begin{bmatrix} 1 & 1 & 2 \\ 0 & 2 & 2 \\ 1 & 0 & 1 \end{bmatrix} \rightarrow \begin{bmatrix} 1 & 1 & 2 \\ 0 & 2 & 2 \\ 0 & -1 & -1 \end{bmatrix} \rightarrow \begin{bmatrix} 1 & 0 & 1 \\ 0 & 1 & 1 \\ 0 & 0 & 0 \end{bmatrix}$$

可知 $\text{rank}(A) = 2$, A 的前两列线性无关, 取出构成 B ; 取出 A 的 Hermite 标准形的前两行作为 C , 有:

$$B = \begin{bmatrix} 1 & 1 \\ 0 & 2 \\ 1 & 0 \end{bmatrix}, C = \begin{bmatrix} 1 & 0 & 1 \\ 0 & 1 & 1 \end{bmatrix}, A = BC$$

(6) 谱分解

定义: 矩阵 A 互异的特征值 $\{\lambda_1, \lambda_2, \dots, \lambda_s\}$ 称为矩阵 A 的谱。可相似对角化是可以谱分解的充要条件。

求法:

- 通过求特征值和特征向量得到 $A = P \begin{bmatrix} \lambda_1 & & & & \\ & \dots & & & \\ & & \lambda_1 & & \\ & & & \lambda_2 & \\ & & & & \dots \\ & & & & & \lambda_2 \\ & & & & & & \dots \\ & & & & & & & \lambda_s \\ & & & & & & & & \dots \\ & & & & & & & & & \lambda_s \end{bmatrix} P^{-1}$;
- 对角阵 $\Lambda = \lambda_1 \begin{bmatrix} I_{r_1} & & & \\ & 0 & & \\ & & \dots & \\ & & & 0 \end{bmatrix} + \lambda_2 \begin{bmatrix} 0 & & & \\ & I_{r_2} & & \\ & & 0 & \\ & & & 0 \end{bmatrix} + \dots + \lambda_s \begin{bmatrix} 0 & & & \\ & 0 & & \\ & & 0 & \\ & & & I_{r_s} \end{bmatrix}$, 令 $Q_i = \begin{bmatrix} 0 & & & \\ & \dots & & \\ & & I_{r_i} & \\ & & & \dots \end{bmatrix}$;
- 得到 $A = \sum_{i=1}^s \lambda_i P_i$, 其中 $P_i = P Q_i P^{-1}$ 。

(7) Schur分解

定义: 对可逆矩阵 A , 存在酉矩阵 U 和主对角线上元素都为正的上三角矩阵 R , 使 $A = UR$ 。

求法:

- 取矩阵 $A = (A_1, A_2, \dots, A_n)$ 的列向量, 进行施密特正交化, 得到 u_1, u_2, \dots, u_n , 有 $U = (u_1, u_2, \dots, u_n)$;
- 再由 $R = U^H A$ 得到 R , 于是 $A = UR$ 。

(8) 几种特殊矩阵:

- 正规矩阵**: $A^H A = A A^H$ (**正规矩阵酉相似于对角阵**)
- 酉矩阵**: $A^H A = A A^H = I$
- Hermite矩阵**: $A^H = A$

(9) 奇异值分解 (SVD分解)

奇异值: 对 $\text{rank}(A) = r$ 的矩阵 A , 矩阵 $A^H A$ 的**非零特征值**有 $\lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_r > 0$, 则称正数 $\sigma_i = \sqrt{\lambda_i}$ 为矩阵 A 的奇异值。

定义: 对 $\text{rank}(A) = r$ 的矩阵 $A \in C^{m \times n}$, 奇异值有 $\sigma_1 \geq \sigma_2 \geq \dots \geq \sigma_r > 0$, 则存在酉矩阵

$$U \in C^{m \times m}, V \in C^{n \times n}, \text{ 分块矩阵 } \Sigma = \begin{bmatrix} \Delta & 0 \\ 0 & 0 \end{bmatrix}, \text{ 有 } A = U \Sigma V^H, \text{ 其中 } \Delta = \begin{bmatrix} \sigma_1 & & & \\ & \sigma_2 & & \\ & & \dots & \\ & & & \sigma_r \end{bmatrix}。$$

求解:

- 由特征多项式 $|\lambda I - A^H A| = 0$ 求得特征值 $\lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_n$, (**务必按照从大到小排列**), 以及每个特征值对应的特征向量 $\alpha_1, \alpha_2, \dots, \alpha_n$;
- 对特征向量进行施密特正交化和单位化 (一般只需要单位化), 得到单位正交向量组 v_1, v_2, \dots, v_n , 则 $V = (v_1, v_2, \dots, v_n)$;
- 对于非零特征值 $\lambda_1, \dots, \lambda_r$ 对应奇异值 $\sigma_1, \dots, \sigma_r$, 于是有 $u_i = \frac{1}{\sigma_i} A v_i$, 这样得到了 r 个列向量, 剩余的设为 β , 通过正交的特性 $u_i^T \beta = 0$ 即可求得,
- 于是得到 $A = U \Sigma V^H$

(10) 极分解

定义: 对于 $\text{rank}(A) = r$ 的矩阵 $A \in C^{m \times n}$, 可以被分解为 $A = PQ$, 其中 P 为半正定矩阵, Q 为酉矩阵。

求法:

- 对 A 进行奇异值分解, 得到 $A = U \Sigma V^H$;
- 可以得到 $A = (U \Sigma U^H)(U V^H)$, 于是 $P = U \Sigma U^H$, $Q = U V^H$, $A = PQ$ 。

4. 矩阵的广义逆

(1) 设 $A \in C^{m \times n}, B \in C^{n \times m}$, 若有 $BA = I_n$, 则称 B 是 A 的一个**左逆**。

等价条件:

- A 的零空间 $N(A) = 0$
- $m \geq n, \text{rank}(A) = n$, 即 A 是**列满秩的**

- $A^H A$ 可逆

(2) 设 $A \in C^{m \times n}$, $C \in C^{n \times m}$, 有 $AC = I_m$, 则称 C 是 A 的一个 **右逆**。

等价条件:

- A 的列空间 $R(A) = C^m$
- $m \leq n$, $rank(A) = m$, 即 A 是 **行满秩**的
- AA^H 可逆

(3) 对于 $A \in C^{m \times n}$, $G \in C^{n \times m}$, 有 $AGA = A$, 称 G 是 A 的一个 **减号广义逆**。

求法:

- 对 $rank(A) = r$ 的矩阵 A , 有矩阵 $\begin{bmatrix} A & I_m \\ I_n & 0 \end{bmatrix}$ 进行 **初等变换**, 对 A 行变换时 I_m 保持同步, 对 A 列变换时, I_n 保持同步, 将 A 化为最简形, 得到 $\begin{bmatrix} I_r & 0 & P \\ 0 & 0 & \\ Q & & 0 \end{bmatrix}$;
- 有 $G = Q \begin{bmatrix} I_r & U \\ V & W \end{bmatrix} P$, 其中 U, V, W 是满足固定阶次的任意矩阵。

(4) **加号广义逆 (M-P逆)**

定义: 对于矩阵 $A \in C^{m \times n}$, $G \in C^{n \times m}$, 满足4条

- $AGA = A$
- $GAG = G$
- $(AG)^H = AG$
- $(GA)^H = GA$

称 G 为 A 的 M-P 逆。

求法:

方法一:

- 对矩阵 A 进行 **满秩分解**, 得到 $A = BC$;
- 则 $A^+ = C^H(CC^H)^{-1}(B^HB)^{-1}B^H$, 也就是等于 C 的右逆 \times B 的左逆。

方法二:

- 对矩阵 A 进行 **奇异值分解**, 得到 $A = U \begin{bmatrix} \Delta & 0 \\ 0 & 0 \end{bmatrix} V^H$;
- 则 $A^+ = V \begin{bmatrix} \Delta^{-1} & 0 \\ 0 & 0 \end{bmatrix} U^H$ 。

性质

- $rank(A) = rank(A^+)$
- $rank(A^+A) = rank(AA^+) = rank(A)$

(5) 投影变换

定义: $C^n = L \oplus M$, $x = y + z$, $y \in L, z \in M$, 投影变换 σ 就是把 C^n 映射成子空间 L , 称 σ 是从 C^n 沿子空间 M 到子空间 L 的投影变换, 在一组基下对应的矩阵称为**投影矩阵**, 子空间 L 称为**投影子空间**。显然有, 子空间 L 就是 σ 的像空间 $R(\sigma)$, M 就是 σ 的核空间 $N(\sigma)$, 于是 $C^n = R(\sigma) \oplus N(\sigma)$ 。

σ 是投影变换的充要条件是 σ 关于某组基下的矩阵 A 是**幂等矩阵**, 即 $A^2 = A$ 。

求法

- 找出像空间 L 的一组基 y_1, y_2, \dots, y_r , 得到矩阵 $B = (y_1 \ y_2 \ \dots \ y_r)$; 找出 M 的一组基 z_{r+1}, \dots, z_n , 得到矩阵 $C = (z_{r+1} \ \dots \ z_n)$;
- 于是有投影矩阵 $A = (B|0)(B|C)^{-1}$ 。

(6) 正交投影变换

定义: 若 $C^n = R(\sigma) \oplus N(\sigma)$, $R(\sigma)$ 的正交补空间是 $R(\sigma)^\perp = N(\sigma)$, 称 σ 是**正交投影变换**, 其在**标准正交基**下对应的矩阵称为正交投影矩阵。

σ 是正交投影变换的充要条件是 A 是**幂等Hermite矩阵**, 即 $A^2 = A$, $A^H = A$ 。

求法

$$A = (B|0)(B|C)^{-1} = (B|0)((B|C)^H(B|C))^{-1}(B|C)^H = B(B^H B)^{-1}B^H$$

(7) 最佳最小二乘解

$A \in C^{m \times n}$, $b \in C^m$, 则 $x_0 = A^+ b$ 是线性方程组 $Ax = b$ 的最佳最小二乘解。

$A \in C^{m \times n}$, $B \in C^{m \times k}$, 则 $X_0 = A^+ B$ 是 $AX = B$ 的最佳最小二乘解。

5. 矩阵分析

(1) **向量范数**满足**正定性**、**齐次性**和**三角不等式**, 定义了范数的内积空间称为**赋范空间**。

(2) 重要的**向量范数**:

对于复向量 $x = (x_1 \ x_2 \ \dots \ x_n)$, 有:

- 2-范数:** $\|x\| = \sqrt{|x_1|^2 + |x_2|^2 + \dots + |x_n|^2}$
- 1-范数:** $\|x\|_1 = |x_1| + |x_2| + \dots + |x_n|$
- ∞ -范数:** $\|x\|_\infty = \max_i |x_i|$

有限维线性空间的任意两种向量范数都是**等价的**。

(3) **矩阵范数**满足**正定性**、**齐次性**、**三角不等式**以及**相容性**。

(4) 重要的**矩阵范数**和**诱导范数**

- **F范数**: $\|A\|_F = [\text{tr}(A^H A)]^{\frac{1}{2}}$
- **列和范数**: $\|A\|_1 = \max_j (\sum_{i=1}^n |a_{ij}|)$, 即每一列各元素模相加其中的最大值
- **谱范数**: $\|A\|_2 = \sqrt{\lambda_1}$, 其中 λ_1 是 $A^H A$ 的最大特征值
- **行和范数**: $\|A\|_\infty = \max_i (\sum_{j=1}^n |a_{ij}|)$, 即每一行各元素模相加其中的最大值

(5) 向量收敛和矩阵收敛必须其中的每一个元素都收敛。

向量按分量收敛的充要条件是它按任意一个向量范数收敛。

当 $k \rightarrow \infty$ 时, $\|A^{(k)} - A\| \rightarrow 0$, 称矩阵序列按矩阵范数收敛于 A

(6) 谱半径

定义: $\lambda_1, \lambda_2, \dots, \lambda_n$ 是矩阵 $A \in C^{n \times n}$ 的全部特征值, 称 $\rho(A) = \max_i |\lambda_i|$ 为 A 的谱半径。

$A^k \rightarrow 0 (k \rightarrow \infty)$ 的充要条件是 $\rho(A) < 1$ 。

A 的谱半径是 A 的任意一种矩阵范数的下确界。

(7) 矩阵幂级数

若复变量 z 的幂级数 $\sum_{k=0}^{\infty} a_k z^k$ 的收敛半径为 R , 而方阵 $A \in C^{n \times n}$ 的谱半径为 $\rho(A)$, 则

- 当 $\rho(A) < R$ 时, 矩阵幂级数 $\sum_{k=0}^{\infty} a_k A^k$ 收敛;
- 当 $\rho(A) > R$ 时, 矩阵幂级数 $\sum_{k=0}^{\infty} a_k A^k$ 发散

当求解 A 的特征值比较困难时, 由于 A 的每个范数都是谱半径 $\rho(A)$ 的上界, 只需要找到一种特殊的矩阵范数 $\|A\|$, 使得 $\|A\| < R$, 就能说明矩阵幂级数收敛。 (优先考虑行和、列和范数)

(8) 常用的幂级数

收敛域是整个复平面的幂级数

$$e^A = \sum_{k=0}^{\infty} \frac{1}{k!} A^k$$

$$\cos A = \sum_{k=0}^{\infty} \frac{(-1)^k}{(2k)!} A^{2k}$$

$$\sin A = \sum_{k=0}^{\infty} \frac{(-1)^k}{(2k+1)!} A^{2k+1}$$

收敛域为复平面 $|z| < 1$ 的幂级数

$$(I - A)^{-1} = \sum_{k=0}^{\infty} A^k, \quad \rho(A) < 1$$

$$\ln(I + A) = \sum_{k=1}^{\infty} \frac{(-1)^{k-1}}{k} A^k, \quad \rho(A) < 1$$

(9) 矩阵函数的两种求法

方法一: Jordan标准形法

- 求矩阵 A 的Jordan标准形 J_A , 得到 $A = P J_A P^{-1}$

- 设解析函数为 $f(z)$, 则对每一个Jordan块有 $f(J_i) = \begin{bmatrix} f(\lambda_i) & \frac{f'(\lambda_i)}{1!} & \frac{f''(\lambda_i)}{2!} & \cdots \\ & f(\lambda_i) & \frac{f'(\lambda_i)}{1!} & \cdots \\ & & \cdots & \\ & & & f(\lambda_i) \end{bmatrix}$, 得到 $f(J_A)$
- 最后得到 $f(A) = Pf(J_A)P^{-1}$

这种方法的难点在于需要求Jordan链, 过程中可以会遇到麻烦。如果不同特征值个数较多, 建议使用第一种; 而如果特征值比较单一, 并且代数重数-几何重数 > 2 , 建议使用第二种。

方法二: 最小多项式法

- 先计算 A 的Jordan标准形, 由此得到最小多项式 $m_A(\lambda) = (\lambda - \lambda_1)^{n_1}(\lambda - \lambda_2)^{n_2} \cdots (\lambda - \lambda_s)^{n_s}$, 其中幂次和有 $\sum_{i=1}^s n_i = m$;
- 得到 $g(\lambda) = c_0 + c_1\lambda + \cdots + c_{m-1}\lambda^{m-1}$, 并令 $g^{(j)}(\lambda_i) = f^{(j)}(\lambda_i)$, 解得系数 c_0, c_1, \dots, c_{m-1} ;
- 最后得到 $f(A) = c_0I + c_1A + \cdots + c_{m-1}A^{m-1}$

当不同特征值的个数比较多或者最小多项式幂次较高时, 计算起来比较复杂, 建议使用第一种。

(10) 两个知识点:

重要的导数

- $\frac{dA^{-1}(t)}{dt} = -A^{-1}(t)\left(\frac{d}{dt}A(t)\right)A^{-1}(t)$

矩阵指数函数的行列式

- $|e^A| = e^{trA}$

(11) 矩阵函数应用

一阶常系数齐次微分方程组: $\begin{cases} \dot{x}(t) = Ax(t) \\ x(t_0) = C_{n \times 1} \end{cases}$

解为: $x(t) = e^{A(t-t_0)}x(t_0)$

一阶线性常系数非齐次线性方程组: $\begin{cases} \dot{x}(t) = Ax(t) + f(t) \\ x(t_0) = C \end{cases}$

解为: $x(t) = e^{A(t-t_0)}x(t_0) + \int_{t_0}^t e^{A(t-\tau)}f(\tau)d\tau$

6. K积

(1) 对于矩阵 $A = (a_{ij}) \in C^{m \times n}$, $B = (b_{ij}) \in C^{s \times t}$, 则K积为:

$$A \otimes B = \begin{bmatrix} a_{11}B & a_{12}B & \cdots & a_{1n}B \\ a_{21}B & a_{22}B & \cdots & a_{2n}B \\ \cdots & \cdots & \cdots & \cdots \\ a_{n1}B & a_{n2}B & \cdots & a_{nn}B \end{bmatrix}$$

K积不具有交换律, 即 $A \otimes B \neq B \otimes A$

(2) 重要性质

- $I \otimes I = I$
- $(A \otimes B)(C \otimes D) = (AC) \otimes (BD)$
- $(A \otimes B)^k = A^k \otimes B^k$
- $(A \otimes B) = (I_m \otimes B)(A \otimes I_n)$
- $(A \otimes B)^{-1} = A^{-1} \otimes B^{-1}$
- $|A \otimes B| = |B \otimes A| = |A|^n |B|^m$ (这里的 n 表示 B 的阶数, m 表示 A 的阶数)
- $\text{rank}(A \otimes B) = \text{rank}(A)\text{rank}(B)$

(3) K和: 设 $A \in F^{m \times m}$, $B \in F^{n \times n}$, $A \oplus B = A \otimes I_n + I_m \otimes B$

(4) 若 A 的特征值是 λ_i , 相应的特征向量是 x_i ; B 的特征值是 μ_i , 相应的特征向量为 y_i ; 则:

- $A \otimes B$ 的特征值是 $\lambda_i \mu_i$, 对应的特征向量是 $x_i \otimes y_i$
- $A \oplus B$ 的特征值是 $\lambda_i + \mu_i$, 对应的特征向量是 $x_i \otimes y_i$

(5) 设 $f(z)$ 是解析函数, $A \in F^{n \times n}$, $f(A)$ 存在, 则

- $f(I_m \otimes A) = I_m \otimes f(A)$
- $f(A \otimes I_m) = f(A) \otimes I_m$

(6) 设矩阵 $A \in F^{m \times n}$, $A = (A_1, A_2, \dots, A_n)$, 则 $\text{Vec}(A) = \begin{bmatrix} A_1 \\ A_2 \\ \vdots \\ A_n \end{bmatrix} \in F^{nm}$

$$\text{Vec}(ABC) = (C^T \otimes A)\text{Vec}(B)$$

- $\text{Vec}(AX) = (I_s \otimes A)\text{Vec}(X)$
- $\text{Vec}(XC) = (C^T \otimes I_k)\text{Vec}(X)$

(7) 求解矩阵方程 $AX + XB = D$, 将两边同时取向量化算子, 得到 $(I_m \otimes A + B^T \otimes I_n)\text{Vec}(X) = \text{Vec}(D)$, 最后通过常规的求非齐次线性方程组的方法求解。

(8) 求微分方程:
$$\begin{cases} \dot{X}(t) = AX(t) + X(t)B \\ X(0) = C \end{cases}$$

- 用向量化算子作用在方程两边, 得到 $\text{Vec}(\dot{X}(t)) = (I_n \otimes A + B^T \otimes I_m)\text{Vec}(X(t))$ 和 $\text{Vec}(X(0)) = \text{Vec}(C)$
- 令 $Y(t) = \text{Vec}(X(t))$, $C_1 = \text{Vec}(C)$, $G = I_n \otimes A + B^T \otimes I_m$, 通过求解普通微分方程的方法得到 $Y(t) = e^{Gt} C_1$;
- 将 $Y(t)$, G , C_1 带入化简求得 $X(t)$ 。